

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΑ

ΣΧΟΛΗ ΤΕΧΝΟΛΟΓΙΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΕΠΙΚΟΙΝΩΝΙΩΝ
ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Αναγνώριση προτύπων Υπολογιστική εργασία 2021-2022 Εξάμηνο 5°

Ιωάννης-Ιάσων Μποϊδάνης π19217 Ευθύμιος-Πάτροκλος Γεωργιάδης π19031

Καθηγητής Δ. Σωτηρόπουλος

Επισυνάπτονται: ένα αρχείο matlab για ευκολία στην αναπαράσταση δεδομένων και ένα αρχείο python για την υπολογιστική διαδικασία(το οποίο διαθέτει τα απαραίτητα γραφήματα, απλά είναι πιο δύσχρηστο)

Περιεχόμενα

Αρχεία κώδικα	σελ 3
Ερώτημα 1	σελ 7
Ερώτημα 2	σελ 7
Ερώτημα 3	σελ 8
Ερώτημα 4	σελ 8
Ερώτημα 5	σελ 8
Ερώτημα 6	σελ 11
Ερώτημα 7	σελ 14
Ερώτημα 9	σελ 17

Κώδικας

```
import tensorflow as tf

from keras.models import Sequential
from keras.layers import Dense
from tensorflow.keras.optimizers import Adam
from keras.callbacks import EarlyStopping

import pandas as pd
import numpy as np
import padasip as pad
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import OneHotEncoder
import sklearn
from sklearn import preprocessing
from sklearn.model selection import train_test_split
from sklearn.metrics import r2_score

from matplotlib import pyplot as plt
```

```
def normalizedata(dt):
        return (dt - np.min(dt)) / (np.max(dt) - np.min(dt))
scaled_long = normalizedata(data.longitude)
plt.show()
plt.show()
scaled_lat = normalizedata(data.latitude)
scaled_age = normalizedata(data.housing_median_age)
scaled_room = normalizedata(data.total_rooms)
scaled_bed = normalizedata(data.total_bedrooms)
scaled_pop = normalizedata(data.population)
scaled_houses = normalizedata(data.households)
scaled_income = normalizedata(data.median_income)
scaled_value = normalizedata(data.median_nouse_value)
 from sklearn.preprocessing import MinMaxScaler
'median_house_value']])
one_hot= pd.get_dummies(housing['ocean_proximity'])
housing = housing.drop('ocean_proximity',axis=1)
housing=housing.join(one hot)
'''label_encoder = LabelEncoder()
integer_encoded = label_encoder.fit_transform(data.ocean_proximity)
# print(integer_encoded)
onehot_encoder = OneHotEncoder(sparse=False)
integer_encoded = integer_encoded.reshape(len(integer_encoded), 1)
onehot_encoded_ocean = onehot_encoder.fit_transform(integer_encoded)
# print(onehot_encoded_ocean)
scaled_ocean = normalizedata(onehot_encoded_ocean)'''
#housing = np.c_[scaled_long, scaled_lat, scaled_age, scaled_room, scaled_bed, scaled_pop, scaled_houses, scaled_income, scal
# print(scaled_ocean)
 #print(housina)
    ''plt.scatter(scaled_long, scaled_lat)
 plt.scatter(scaled_value,scaled_income)
 plt.show()
plt.hist(data.longitude, bins=16, density=True, stacked=True)
# pit.legend()
plt.title('Histogram 1')
plt.xlabel('Longitude')
plt.ylabel('Prob dencity')
plt.show()
```

```
plt.hist(data.latitude, bins=16, density=True, stacked=True)
plt.title('Histogram 2')
plt.xlabel('latitude')
plt.ylabel('Prob dencity')
plt.show()
plt.hist(data.housing_median_age, bins=16, density=True, stacked=True)
plt.title('Histogram 3')
plt.xlabel('age')
plt.ylabel('Prob_dencity')
plt.show()
plt.hist(data.total_rooms, bins=64, density=True, stacked=True)
plt.title('Histogram 4')
plt.xlabel('rooms')
plt.ylabel('Prob dencity')
plt.show()
plt.hist(data.total_bedrooms, bins=64, density=True, stacked=True)
plt.title('Histogram 5')
plt.xlabel('beds')
plt.ylabel('Prob dencity')
plt.show()
plt.hist(data.population, bins=64, density=True, stacked=True)
plt.title('Histogram 6')
plt.xlabel('population')
plt.ylabel('Prob dencity')
plt.show()
plt.hist(data.households, bins=64, density=True, stacked=True)
plt.title('Histogram 7')
plt.xlabel('houses')
plt.ylabel('Prob dencity')
plt.show()
plt.hist(data.median_income, bins=16, density=True, stacked=True)
plt.title('Histogram 8')
plt.xlabel('income')
plt.ylabel('Prob dencity')
plt.ylabel('Prob dencity')
plt.show()
plt.hist(data.ocean proximity, bins=16, density=True, stacked=True)
plt.mist(additional proxim
plt.title('Histogram 9')
plt.xlabel('ocean')
plt.ylabel('Prob dencity')
plt.show()
print(data.ocean_proximity)
print(data.median_house_value)
print(data.median_income)
print(data.households)
print(data.population)
print(data.total_bedrooms)
print(data.total_rooms)
print(data.housing_median_age)
print(data.latitude)
print(data.longitude)
```

```
plt.title('Histogram 9')
plt.xlabel('ocean')
plt.ylabel('Prob dencity')
plt.show()

plt.hist(data.median_house_value, bins=16, density=True, stacked=True)
plt.title('Histogram 10')
plt.xlabel('value')
plt.ylabel('Prob dencity')
plt.show()
```

```
#Y_true = np.c[
    # scaled_long, scaled_lat, scaled_bed, scaled_age, scaled_room, scaled_income, scaled_pop, scaled_houses, scaled_o
# print(Y_true)
#Y_pred = np.c[scaled_value]
# print(Y_pred)
#MSE = np.square(np.subtract(Y_true.transpose(), Y_pred.transpose())).mean()
#print(MSE)
#Y Pred=Y pred.transpose()
#Y Pred=Y pred.transpose()
#12 = housing['median_house_value']

df1 = housing.drop('median_house_value',axis=1)
X_train, X_test, y_train, y_test = train_test_split(df1, df2, test_size=0.2)
# Plots the results of a learning rate of 100, 1000, and 10000 respectively, with all other parameters constant
```

```
In [3]:
    #X_train = preprocessing.scale(X_train)
    print(df1)
    #X_test = preprocessing.scale(X_test)
                                  20635 0.324701 0.737513
20636 0.312749 0.738576
20637 0.311753 0.732200
20638 0.301793 0.732200
20639 0.309761 0.725824
                                                                                                        0.470588
0.333333
0.313725
0.333333
0.294118
                                                                                                                                     0.042296
0.017676
0.057277
0.047256
0.070782
                                                                                                                                                                          0.057883
0.023122
0.075109
0.063315
0.095438

        population
        households
        median_income
        <1H OCEAN</th>
        INLAND
        ISLAND
        \( \)

        0.088941
        0.026556
        0.533668
        0
        0
        0
        0

        0.067210
        0.186976
        0.538027
        0
        0
        0

                                        0.008941
0.067210
0.013818
                                                                  0.020556
0.186976
0.028943
                                                                                                     0.466028
0.354699
0.230776
                                        0.015555
0.015752
                                                                   0.035849
0.042427
                                      0.023599
0.009894
0.028140
0.020684
0.038790
                                                                  0.054103
0.018582
0.071041
0.057227
                                                                                                    0.073130
0.141853
0.082764
0.094295
                   20635
20636
20637
20638
                                                                   0.086992
                    20639
                                                                                                    0.130253
                                    NEAR BAY NEAR OCEAN
                   20635
20636
20637
                    20638
20639
                   [20640 rows x 13 columns]
 In [4]: print(df2)
                                       0.902266
0.708247
0.695051
                                      0.130105
0.128043
0.159383
0.143713
0.153403
                   20635
20636
20637
                    20639
                    Name: median house value, Length: 20640, dtype: float64
 In [7]: LR = [100,1000,10000]
                   for i in LR:
    #Defines linear regression model and its structure
    model = Sequential()
    model.add(Dense(1, input_shape=(13,)))
                             #Compiles model
model.compile(Adam(learning_rate=i), 'mean_squared_error')
                             #Fits model history = model.fit(X_train, y_train, epochs = 500, validation_split = 0.1,verbose = 0) history_dict=history.history
                            #Plots model's training cost/loss and model's validation split cost/loss
loss values = history_dict['loss']
val_loss_values=history_dict['val_loss']
plt.figure()
plt.plot(loss_values,'bo',label='training loss')
plt.plot(val_loss_values,'r',label='val training loss')
```

```
In [8]: # Runs and plots the performance of a model with the same parameters from before (and a learning rate of 10000,
# but now with an activation function (Relu)

model = Sequential()
model.add(Dense(1, input_shape=(13,), activation = 'relu'))
model.compile(Adam(learning_rate=10000), 'mean_squared_error')
history = model.fit(X_train, y_train, epochs = 500, validation_split = 0.1,verbose = 0)

history_dict=history.history
loss_values = history_dict['loss']
val_loss_values=history_dict['val_loss']
plt.plot(loss_values, 'bo', label='training_loss')
plt.plot(val_loss_values, 'r', label='training_loss val')
```

1) αποδίδουμε τιμές στα χαρακτηριστικά

(με δύο τρόπους για να τα χρησιμοποιήσουμε σε διαφορετικά σημεία)

```
plt.rcParams["figure.figsize"] = [7.00, 3.50]
plt.rcParams["figure.autolayout"] = True
columns = ["longitude", "latitude", "housing_median_age", "total_rooms"
    , "total_bedrooms", "population", "households", "median_income",
"median_house_value", "ocean_proximity"]
data = pd.read_csv("housing.csv", usecols=columns)
housing = pd.read csv("housing.csv")
M= readmatrix('housing.csv');
long = M(:,1);
lat = M(:,2);
age =M(:,3);
room = M(:,4);
bed = M(:,5);
pop = M(:,6);
houses = M(:,7);
income = M(:,8);
value = M(:,9);
ocean = M(:,10);
```

2) κάνουμε scaling των δεδομένων

```
scaled long = normalizedata(data.longitude)
plt.show()
scaled_lat = normalizedata(data.latitude)
scaled_age = normalizedata(data.housing_median_age)
scaled_room = normalizedata(data.total_rooms)
scaled_bed = normalizedata(data.total_bedrooms)
scaled_pop = normalizedata(data.population)
scaled houses = normalizedata(data.households)
scaled_income = normalizedata(data.median_income)
scaled_value = normalizedata(data.median_house_value)
from sklearn.preprocessing import MinMaxScaler
min_max_scaler = MinMaxScaler()
housing[['longitude','latitude','housing_median_age', 'total_rooms'
   , 'total_bedrooms', 'population', 'households', 'median_income'
               median_house_value']]=min_max_scaler.fit_transform(housing[['longitude','latitude','housing_median_age',
     , 'total_bedrooms', 'population' median_house_value']])
                              'population',
                                               'households',
                                                                  'median income'
```

```
long = rescale(long); %rescaling to [0,1]
                                                pop = rescale(pop);
%mean_lat = mean(lat);
%lat = fillmissing(lat,"constant",mean_lat);
                                               %mean_houses = mean(houses);
lat = rescale(lat);
                                                %houses = fillmissing(houses,"constant",mean_ho
                                                houses = rescale(houses);
%mean_age= mean(age);
%age = fillmissing(age,"constant",mean_age);
                                                %mean_in = mean(income);
age = rescale(age);
                                                %income = fillmissing(income, "constant", mean in
                                                income = rescale(income);
%mean_room = mean(room);
%room = fillmissing(room, "constant", mean_room);
room= rescale(room);
                                                value = rescale(value);
```

3) one hot vector

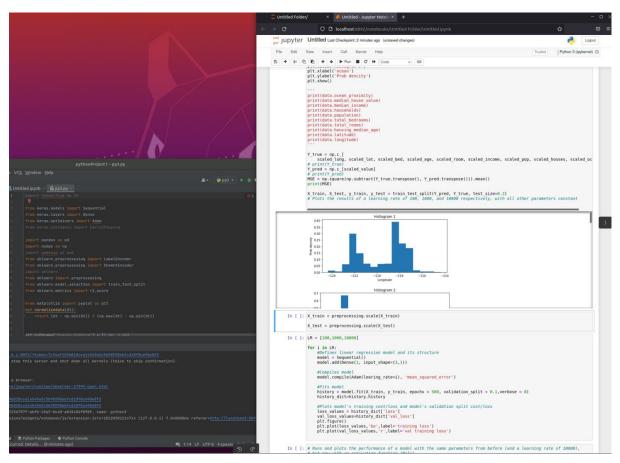
```
one_hot= pd.get_dummies(housing['ocean_proximity'])
housing = housing.drop('ocean_proximity',axis=1)
housing=housing.join(one_hot)
```

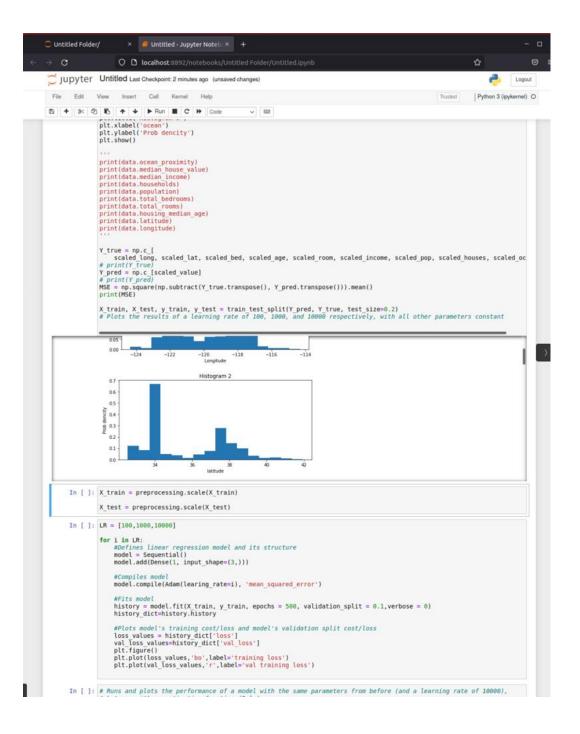
4)για τις ελλιπείς τιμές των υπνοδωματίων

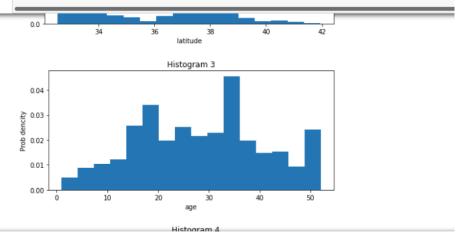
```
data.fillna(data.total_bedrooms.mean(),inplace=True)

mean_bed = nanmean(bed);
bed = fillmissing(bed, "constant", mean_bed);
```

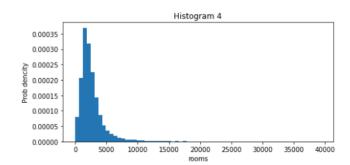
5)αναπαράσταση ιστογραμμάτων των συναρτήσεων πυκνότητας πιθανότητας για τα 10 χαρακτηριστικά

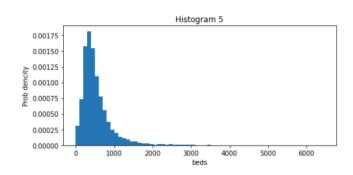


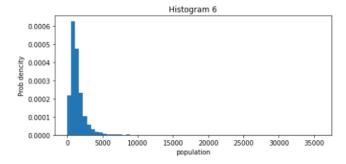


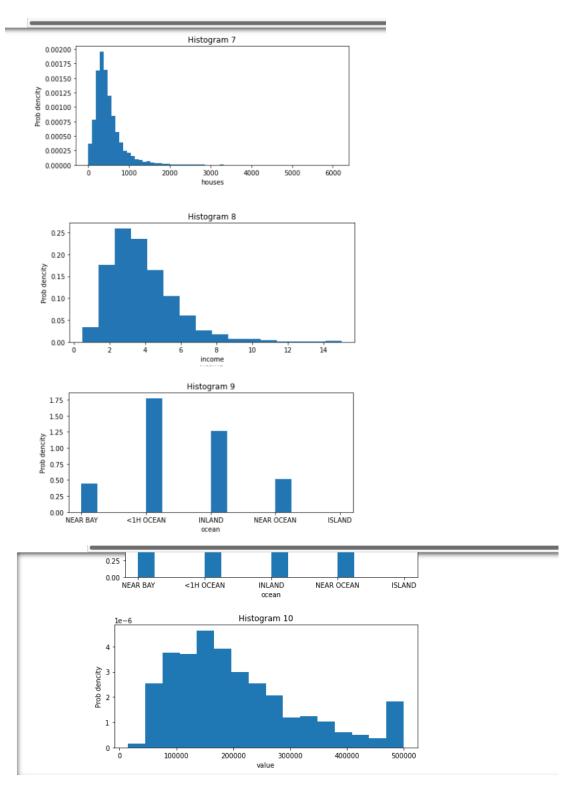


HISTOGRAM 4

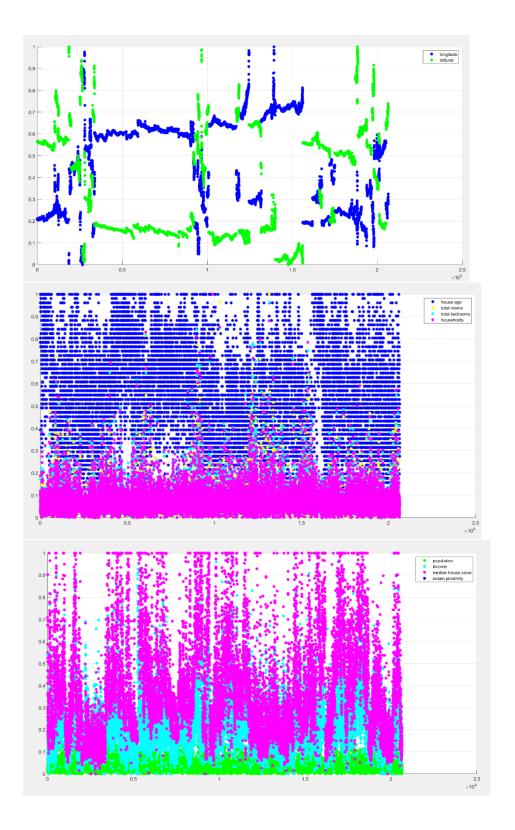


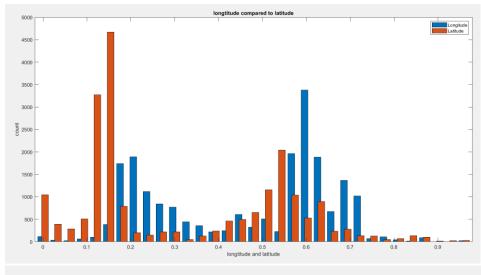


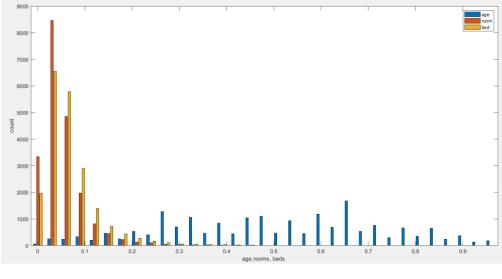


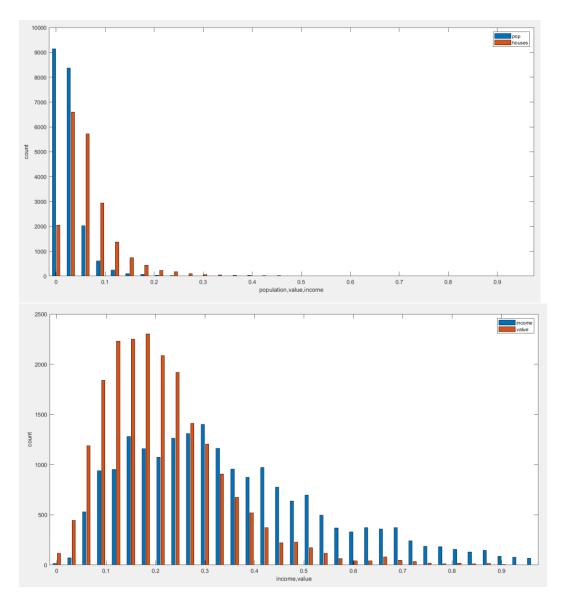


6)συνδυασμοί μεταβλητών σε μορφή σημείων(scaled εκδοχής) και ιστογραμμάτων πυκνότητας εμφάνισης των πραγματικών τιμών









7)αλγόριθμος mse

Ετοιμάζουμε τα δεδομένα μας, και ορίζουμε πλήθος προτύπων για εκπαίδευση

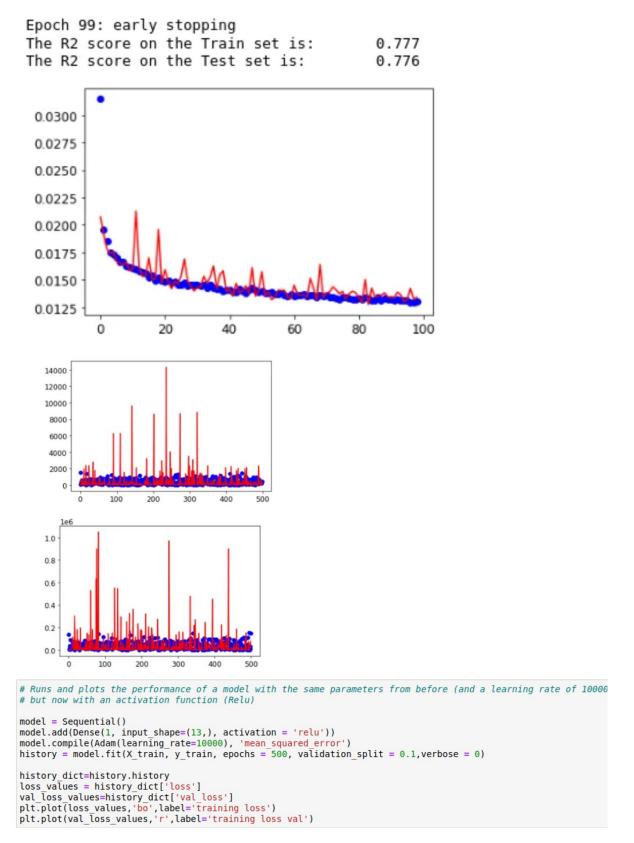
```
#Y_true = np.c_[
    # scaled_long, scaled_lat, scaled_bed, scaled_age, scaled_room, scaled_income, scaled_pop, scaled_houses, scaled_o
# print(Y_true)
#V pred = np.c_[scaled_value]
# print(Y_pred)
#MSE = np.square(np.subtract(Y_true.transpose(), Y_pred.transpose())).mean()
#print(MSE)
#V Pred=Y_pred.transpose()
df2 = housing['median_house_value']
df1 = housing.drop('median_house_value',axis=1)
X_train, X_test, y_train, y_test = train_test_split(df1, df2, test_size=0.2)
# Plots the results of a learning rate of 100, 1000, and 10000 respectively, with all other parameters constant
```

Τα δεδομένα μας είναι σε μορφή έτοιμη για παλινδρόμηση και στις σωστές διαστάσεις

```
In [3]:
    #X train = preprocessing.scale(X_train)
    print(df1)
    #X_test = preprocessing.scale(X_test)
                      0.209163 0.564293
                                                                   1.000000
                                                                                        0.041330
                                                                                                               0.043296
            20635 0.324701 0.737513
20636 0.312749 0.738576
20637 0.311753 0.732200
                                                                    0.470588
0.333333
                                                                                        0.042296
0.017676
                                                                                                               0.057883
                                                                     0.313725
                                                                                        0.057277
                                                                                                                0.075109
             20638 0.301793 0.732200
20639 0.309761 0.725824
                                                                    0.294118
                                                                                        0.070782
                                                                                                               0.095438
                       population households median_income <1H OCEAN INLAND ISLAND \ 0.008941 0.020556 0.539668 0 0 0
                                          0.186976
0.028943
                          0.067210
0.013818
                                                                 0.538027
0.466028
                          0.015555
0.015752
                                           0.035849
0.042427
                                                                 0.230776
                                                                  0.141853
0.082764
                       NEAR BAY NEAR OCEAN
            20635
20636
20637
            [20640 rows x 13 columns]
In [4]: print(df2)
            20635 0.130105
20636 0.128043
20637 0.159383
             20636
20637
             Name: median house value, Length: 20640, dtype: float64
In [7]: LR = [100,1000,10000]
            for i in LR:
    #Defines linear regression model and its structure
                  model.add(Dense(1, input shape=(13,)))
                  model.compile(Adam(learning rate=i), 'mean squared error')
                  ##11S modet
history = model.fit(X_train, y_train, epochs = 500, validation_split = 0.1,verbose = 0)
history_dict=history.history
                  #Plots model's training cost/loss and model's validation split cost/loss
loss values = history_dict['loss']
val_loss_values=history_dict['val_loss']
plt.figure()
plt.plot(loss_values,'bo',label='training loss')
plt.plot(val_loss_values,'r',label='val_training loss')
```

13ις ως αποτέλεσμα του one hot vector encoding όπου χώρισε το χαρακτηριστικό ocean proximity στις 5 κατηγορίες που έχει.

Στη συνέχεια επαναληπτικά εφαρμόζουμε τον αλγόριθμο δημιουργώντας μοντέλα με την μέθοδο της βιβλιοθήκης keras όπου το 10% των συνολικών προτύπων για εκπαίδευση θα επιλεγούν με δειγματοληψία για να ελεγχθεί το σφάλμα. Όπου θα αναπαρασταθούν με μπλε γραμμή για το train και το training test error με κόκκινη. (χωρίς να βγει ολοκληρωμένο αποτέλεσμα λόγω πτώσης συστήματος κι αδυναμία κάρτας γραφικών δεν μπορούσαν να τρέξουν πολύ ώρα τα τεστ).



(Κάποιες φορές δεν τρέχουν τα γραφήματα)

Τα αποτελέσματα του πρώτου νευρωνικού δικτύου(με ένα κρυφό επίπεδο) βγαίνουν αρνητικά διότι έχουμε βάλει λίγα πρότυπα για εκπαίδευση, καθώς με ένα οποιοδήποτε μεγαλύτερο

νούμερο αδυναμεί το σύστημα να βγάλει γραφική αναπαράσταση σε ένα ουσιώδες χρονικό διάστημα.

Για το 9° ερώτημα παράγουμε ένα νευρωνικό δίκτυο πολλών επιπέδων για την διαδικασία μάθησης. Με σταθερό ρυθμό μάθησης



